Proyecto Final

Análisis de los hábitos de escucha en Spotify

Técnicas de Ciencia de Datos
Universidad de la Rioja

Realizado por:

Pablo Galilea Valverde
Jorge Jiménez Sáenz de Tejada

Logroño, Año 2026

Índice general

1. Planteamiento del problema **1**
- 1.1. Contexto . . . 1
- 1.2. Análisis de negocio . . . 1
- 1.3. Objetivo del proyecto . . . 1
- 1.4. Marco metodológico y alcance . . . 2

2. Datos recogidos **3**
- 2.1. Fuentes de datos . . . 3
- 2.2. Acceso a los datos . . . 3
  - 2.2.1. Autenticación en Spotify . . . 3
  - 2.2.2. Autenticación en Last.fm y Deezer . . . 3
  - 2.2.3. Gestión de credenciales . . . 4
- 2.3. Datos obtenidos . . . 4
- 2.4. Problemas de calidad e integración detectados . . . 5

3. Tratamiento de los datos **6**
- 3.1. Herramientas y librerías utilizadas . . . 6
- 3.2. Formato de los datos . . . 6
- 3.3. Proceso de obtención de los datos base . . . 7
- 3.4. Proceso de enriquecimiento . . . 8
- 3.5. Privacidad y reproducibilidad . . . 8
- 3.6. Decisiones de diseño . . . 9

4. Diseño del modelo de datos **10**
- 4.1. Estructura de partida y consolidación . . . 10
- 4.2. Enriquecimiento con fuentes adicionales . . . 11
- 4.3. Tratamiento de valores nulos . . . 12
- 4.4. Características y variables del modelo . . . 12
- 4.5. Métodos de análisis . . . 13
  - 4.5.1. Compatibilidad y estabilidad . . . 13
  - 4.5.2. Afinidad usuario–artista . . . 13
  - 4.5.3. Agrupamiento de artistas . . . 14
- 4.6. Decisiones de implementación y reproducibilidad . . . 14
- 4.7. Limitaciones del modelo . . . 15

5. Resultados y visualización **16**
- 5.1. Composición y diversidad de etiquetas . . . 16
- 5.2. Coincidencia entre ventanas temporales . . . 18
- 5.3. Compatibilidad entre usuarios . . . 19
- 5.4. Cobertura de las fuentes y tratamiento de ausencias . . . 20
- 5.5. Popularidad externa y posición personal . . . 21
- 5.6. Afinidad de candidatos nuevos . . . 22
- 5.7. Agrupamiento exploratorio . . . 23

6. Conclusiones **26**
6.1. Respuesta a las preguntas del proyecto 26
6.2. Aprendizajes del proceso de ciencia de datos 27
6.3. Limitaciones y trabajo futuro 27

Bibliografía **28**

Capítulo 1: Planteamiento del problema

Contexto

Spotify es una de las plataformas de streaming musical con mayor número de usuarios a nivel mundial. A través de su API pública (*Spotify Web API*) permite, previa autenticación del propio usuario, consultar información agregada sobre sus hábitos de escucha: artistas más reproducidos, canciones favoritas, listas de reproducción, etc.

Este proyecto nace con el objetivo de aplicar el ciclo de vida de un proyecto de ciencia de datos —presentado en la primera sesión de la asignatura— sobre un conjunto de datos propio y personal: el historial de artistas más escuchados de los autores de este trabajo, enriquecido con información de género y de similitud obtenida de Last.fm y con una segunda medida de popularidad procedente de Deezer.

Análisis de negocio

Siguiendo el esquema de preguntas planteado en la asignatura para delimitar el objetivo de un proyecto de ciencia de datos (¿cuánto?, ¿qué categoría?, ¿qué grupo?, ¿es esto raro?, ¿qué opción se debe tomar?), este trabajo se sitúa principalmente en torno a las preguntas de **categorización**, **agrupamiento** y **comparación**:

- ¿Qué géneros musicales predominan en los gustos de cada usuario?
- ¿Es estable el gusto musical en el tiempo, o varía al comparar el corto plazo (*short_term*, últimas 4 semanas), el medio plazo (*medium_term*, últimos 6 meses) y el largo plazo (*long_term*, varios años)?
- ¿Existen agrupaciones naturales de artistas que permitan describir el perfil musical de forma más compacta que una simple lista?
- ¿Qué diferencias y similitudes existen entre los perfiles musicales de los dos autores del trabajo?
- ¿Se comportan los autores de forma parecida respecto a la popularidad de los artistas que escuchan?
- ¿Se puede estimar, para un artista ajeno al historial, si encaja con el gusto de un usuario a partir de la similitud con sus artistas favoritos?

Objetivo del proyecto

El objetivo principal es construir, a partir de datos personales obtenidos mediante la API de Spotify, un conjunto de datos estructurado que recoja los artistas más escuchados por cada autor en los tres rangos temporales disponibles, junto con los géneros musicales asociados a cada artista y otros atributos de popularidad y similitud. Sobre ese conjunto de datos se realiza:

- Un análisis descriptivo de la diversidad y la evolución del gusto musical (distribución de géneros, comparación entre rangos temporales y entre usuarios).
- Un análisis de compatibilidad entre los dos autores mediante métricas de similitud sobre artistas y géneros.
- Un análisis de popularidad, relacionando el ranking personal con los oyentes de Last.fm y contrastando estos con los fans de Deezer.
- Una estimación de afinidad usuario–artista para artistas nuevos, basada en la vecindad de similitud proporcionada por Last.fm.
- Un *clustering* exploratorio de artistas por sus etiquetas, incorporado como ampliación metodológica propia del proyecto.
- La visualización de los resultados mediante los tipos de gráficos estudiados en la asignatura, justificando en cada caso el tipo elegido.

Marco metodológico y alcance

La organización sigue las fases de comprensión del problema, comprensión y preparación de los datos, modelado, evaluación y comunicación de CRISP-DM, presentada en la Sesión 1 [2]. La entrega es un estudio exploratorio, no el despliegue de un sistema de recomendación. La selección de fuentes, limpieza y formatos se fundamenta en las Sesiones 1–3, y la comunicación visual en la Sesión 6. Jaccard, coseno, Spearman y K-Means son elecciones metodológicas del proyecto, no requisitos atribuidos al material docente.

Los CSV contienen **rankings agregados**, no un registro de reproducciones: no se conoce el tiempo de escucha ni cuántas veces se ha reproducido cada artista. Los rangos temporales se solapan y no son tres observaciones longitudinales independientes. Por ello se describe la coincidencia entre ventanas, sin inferir tendencias causales ni generalizar a una población.

El enunciado permite elegir las fuentes y el problema [1]; no exige usar todas las técnicas de las sesiones. No se añaden análisis geográficos ni de grafos porque las preguntas delimitadas pueden abordarse con las variables disponibles.

Capítulo 2: Datos recogidos

Fuentes de datos

Siguiendo la clasificación de fuentes públicas de datos vista en la asignatura, este proyecto utiliza tres fuentes encuadradas en la categoría de **APIs y datos en tiempo real / redes sociales**:

- **Spotify Web API**, a través de la librería `spotipy` para Python. Es la fuente primaria: proporciona, para el usuario autenticado, su lista de artistas más escuchados (`current_user_top_artists`) en tres rangos temporales.
- **Last.fm API**, fuente secundaria de tres tipos de información: los géneros más representativos de cada artista (`artist.gettoptags`), sus métricas de popularidad (`artist.getInfo`) y su vecindad de artistas similares con una puntuación de similitud (`artist.getSimilar`).
- **Deezer API pública**, utilizada como segunda medida de popularidad (número de fans y álbumes) y para contrastar la cobertura de Last.fm. No requiere autenticación.

Siguiendo la clasificación de fuentes de la Sesión 1 [3], se combinan APIs con acceso autenticado y público. Los rankings de Spotify son **personales y dinámicos**; Last.fm aporta metadatos públicos mediante API key y Deezer permite la búsqueda pública sin credenciales. Las cifras de popularidad y las etiquetas también pueden cambiar, pero no describen la escucha privada del usuario autenticado.

Se evaluó también **MusicBrainz** como fuente de metadatos canónicos (país de origen, año de actividad o identificadores estables). Se descartó porque, sin un análisis geográfico en el alcance del proyecto, no aportaba variables que respondieran a las preguntas planteadas y añadía una consulta adicional por artista.

Acceso a los datos

Autenticación en Spotify

El acceso a los datos de Spotify requiere registrar una aplicación en el panel de desarrolladores de Spotify para obtener un `Client ID` y un `Client Secret`, y autenticar al usuario mediante el flujo OAuth *Authorization Code Flow*, gestionado por `spotipy.oauth2.SpotifyOAuth`. El *scope* solicitado es `user-top-read`, que da acceso de solo lectura a los artistas y canciones más escuchados por el usuario. El token se guarda en una caché local que no se versiona.

Autenticación en Last.fm y Deezer

Last.fm se consulta con una `API key` simple enviada como parámetro en cada petición HTTP. Deezer expone un *endpoint* de búsqueda público que no requiere credenciales. En ambos casos se aplica una pausa entre peticiones y reintentos con espera creciente ante errores temporales o límites de frecuencia.

Gestión de credenciales

Las credenciales (`SPOTIPY_CLIENT_ID`, `SPOTIPY_CLIENT_SECRET`, `SPOTIPY_REDIRECT_URI` y `LASTFM_API_KEY`) se almacenan en un fichero `.env` local, cargado mediante la librería `python-dotenv`, y no se incluyen en el repositorio del proyecto por motivos de seguridad. Cada autor ejecuta la extracción con su propia cuenta de Spotify; las credenciales de la aplicación pueden compartirse, pero el token de acceso es personal.

Datos obtenidos

Para cada uno de los dos autores del trabajo se ejecuta el proceso de extracción, obteniendo un listado de hasta 50 artistas por cada uno de los tres rangos temporales que ofrece la API de Spotify:

Rango (API)	**Significado**	**Etiqueta usada**
`short_term`	Últimas 4 semanas	`ultimas_4_semanas`
`medium_term`	Últimos 6 meses	`ultimos_6_meses`
`long_term`	Varios años (histórico acumulado)	`varios_anios`

Cuadro 2.1: Rangos temporales proporcionados por la API de Spotify para el ranking de artistas más escuchados.

Para cada artista se recogen los siguientes campos:

Campo	**Descripción**	**Fuente**
`rango`	Rango temporal al que pertenece la entrada (ver Tabla 2.1)	Spotify
`posicion`	Posición en el ranking dentro de su rango (1–50)	Spotify
`artista`	Nombre del artista	Spotify
`generos`	Hasta 4 etiquetas de género, separadas por `;`	Last.fm
`spotify_url`	Enlace al perfil del artista en Spotify	Spotify

Cuadro 2.2: Esquema del conjunto de datos recogido por autor (fichero `top_artistas*.csv`).

El conjunto recibido contiene **298 filas**: Pablo aporta 150 (50 por rango) y Jorge 148 (48 en las últimas cuatro semanas y 50 en cada uno de los otros rangos). El rango corto de Jorge tiene posiciones consecutivas 1–48; al solicitarse *hasta* 50 elementos, no se añaden dos observaciones ficticias ni se considera por sí sola una extracción inválida.

Hay 74 artistas únicos de Pablo y 71 de Jorge, con 5 compartidos y **140 artistas en la unión**. No se detectan posiciones duplicadas ni fuera de 1–50. En Pablo hay 146/150 filas con etiquetas y en Jorge 146/148; a nivel de artista único la cobertura es 70/74 y

70/71, respectivamente. Un mismo artista puede aparecer en varios rangos y en ambas cuentas, por lo que las 298 filas no son 298 observaciones independientes.

La fecha registrada para la extracción de Pablo es 3 de noviembre de 2026. La de Jorge no está acreditada en los metadatos recibidos: se mantiene desconocida, separada de la fecha de validación y enriquecimiento. No se afirma por tanto que ambas extracciones sean simultáneas. Los recuentos se conservan en `resultados/extraccion_meta.json`.

Sobre esa base, la tabla de artistas se amplía con los campos de la Tabla 2.3.

Cuadro 2.3: Campos adicionales incorporados por artista.

Campo	**Fuente**	**Descripción**
`listeners`	Last.fm	Número de oyentes únicos del artista
`playcount`	Last.fm	Reproducciones totales registradas
`mbid`	Last.fm	Identificador MusicBrainz del artista
`similar_top`	Last.fm	Artista más similar y su *match score*
`n_similares`	Last.fm	Número de vecinos similares recuperados
`deezer_fans`	Deezer	Número de fans en Deezer
`deezer_nb_album`	Deezer	Número de álbumes en Deezer

Problemas de calidad e integración detectados

- **Cobertura incompleta de etiquetas**: cinco artistas únicos de la unión no tienen géneros. No se deduce la causa de cada ausencia sin una respuesta que la acredite; se conservan para las comparaciones de artistas y se excluyen solo de los cálculos que necesitan etiquetas.
- **Etiquetas de Last.fm ruidosas**: Last.fm permite etiquetas libres de usuario, por lo que junto a géneros reales aparecen etiquetas de nacionalidad (`spanish`, `japanese`, `taiwan`) o metaetiquetas sin valor musical (`seen live`, `favorites`, `my top songs`). Se ha aplicado un filtro manual (`IGNORAR`) para excluir las etiquetas más comunes de este tipo, aunque no es exhaustivo.
- **Cobertura desigual entre fuentes**: los artistas de nicho tienen menos probabilidades de estar dados de alta en Last.fm y Deezer, por lo que los valores nulos no se distribuyen al azar. Su cuantificación y tratamiento se detallan en el Capítulo 4.
- **Redundancia entre rangos**: un mismo artista puede aparecer hasta tres veces (una por rango), por lo que el fichero combinado no está en forma de tabla *artista–atributos* única, sino en formato largo (*long format*), con una fila por combinación artista-rango.
- **Normalización de nombres**: los nombres de artistas provienen directamente de Spotify y se usan tal cual para consultar Last.fm y Deezer; en caso de alias distintos entre plataformas, la búsqueda puede fallar silenciosamente (se guarda cadena vacía o valor nulo).

Capítulo 3: Tratamiento de los datos

Herramientas y librerías utilizadas

El proyecto se ha desarrollado íntegramente en Python, dentro de un entorno virtual reproducible descrito en `requirements.txt`. El trabajo se reparte entre dos cuadernos Jupyter y un módulo de funciones:

- `TrabajoTecnicasDeCienciaDeDatos.ipynb`: extracción de los artistas más escuchados y de sus géneros.
- `AnalisisTecnicasDeCienciaDeDatos.ipynb`: consolidación, enriquecimiento, análisis y generación de figuras.
- `spotify_analisis.py`: funciones reutilizables de cálculo y acceso a fuentes, utilizadas por el cuaderno de análisis.

La Tabla 3.1 recoge las librerías empleadas y su función.

Librería	**Uso en el proyecto**
`spotipy`	Cliente de la Spotify Web API; gestiona el flujo OAuth y las peticiones a `current_user_top_artists`.
`requests`	Peticiones HTTP a Last.fm y Deezer, con reintentos y control de errores.
`pandas`	Consolidación en formato largo, tablas derivadas, agregaciones y exportación.
`numpy`	Operaciones vectoriales y cálculo de la entropía.
`scipy`	Correlación de Spearman y prueba U de Mann-Whitney.
`scikit-learn`	K-Means, coeficiente de silueta y proyección PCA.
`matplotlib` y `seaborn`	Figuras del informe, con estilo homogéneo y 300 dpi.
`python-dotenv`	Carga de credenciales desde el fichero local `.env`.
`jupyterlab`	Ejecución interactiva de los cuadernos.
`time` y `json` (estándar)	Pausas entre peticiones y caché persistente de enriquecimiento.

Cuadro 3.1: Librerías empleadas en el proyecto.

Formato de los datos

Se usa **CSV** (valores separados por comas) para la extracción y los agregados, según el formato tabular estudiado en la Sesión 3 [5]. Los CSV originales están codificados en

`utf-8-sig`: Unicode preserva tanto los acentos como los nombres japoneses, y la marca BOM facilita el reconocimiento de la codificación en Excel. Se lee con esa codificación para que el BOM no pase a formar parte del nombre de la primera columna; los agregados se escriben en UTF-8 sin BOM. Esta decisión aplica los conceptos de repertorio, puntos de código y codificación de la Sesión 2 [4], sin transliterar ni perder caracteres.

Con 298 registros, CSV ofrece inspección sencilla e interoperabilidad con `pandas`. No se necesitan las lecturas parciales, los grupos o los bloques de HDF5, ni la optimización columnar de Parquet descritos en la Sesión 3. La elección se justifica por la escala y la estructura, no porque dichos formatos sean inadecuados en general.

La **caché de enriquecimiento** se guarda en **JSON**, formato de estructura jerárquica y listas estudiado en la Sesión 3 [5]. Cada artista tiene metadatos y una lista de vecinos similares. También se exportan en JSON los metadatos y las métricas; los resultados no calculables se representan como `null`, sin valores `NaN` o infinitos ajenos al estándar.

Las figuras se guardan en PNG a 300 dpi. PNG emplea compresión sin pérdida, de acuerdo con la Sesión 2 [4]: mantiene trazos y etiquetas sin los artefactos de una compresión con pérdida como JPEG.

Proceso de obtención de los datos base

El proceso implementado en el cuaderno de extracción sigue estos pasos:

1. **Autenticación**: se cargan las credenciales desde `.env` y se inicializa el cliente `spotipy.Spotify` con el *scope* `user-top-read`. El token se cachea localmente.

2. **Descarga de artistas por rango**: para cada uno de los tres rangos temporales (Tabla 2.1), se solicita el *top* 50 de artistas más escuchados (`current_user_top_artists`) y se añade cada uno a una lista de registros con su posición, nombre y enlace de Spotify.

3. **Deduplicación antes de consultar géneros**: dado que un mismo artista puede repetirse en varios rangos, se extrae el conjunto de artistas *únicos* antes de consultar Last.fm, para minimizar el número de peticiones y respetar sus límites de uso.

4. **Consulta de géneros en Last.fm**: para cada artista único se solicita `artist.gettoptags`, que devuelve etiquetas con un peso (*count*) entre 0 y 100. Se seleccionan como máximo 4 etiquetas con peso igual o superior a 20, descartando las etiquetas no musicales recogidas en el conjunto `IGNORAR` (nacionalidades, tipo de voz, metaetiquetas).

5. **Combinación**: los géneros se incorporan al `DataFrame` mediante un mapeo artista → géneros, evitando repetir la consulta para un artista presente en varios rangos.

6. **Exportación**: el resultado se guarda como `top_artistas.csv` o `top_artistasJorge.csv` según el autor, con las columnas `rango`, `posicion`, `artista`, `generos` y `spotify_url` (Tabla 2.2).

Proceso de enriquecimiento

Sobre el conjunto de artistas únicos de ambos autores, el cuaderno de análisis realiza tres consultas por artista:

1. **Last.fm** `artist.getInfo`: oyentes, reproducciones e identificador MusicBrainz.
2. **Last.fm** `artist.getSimilar`: hasta 20 artistas similares con su *match score*.
3. **Deezer**: búsqueda pública del artista para obtener fans y número de álbumes.

Las respuestas válidas se guardan en `cache/enriquecimiento.json` con una clave por artista y consulta. Antes de cada llamada se comprueba la caché. Se pausa 0,25 s en Last.fm y 0,1 s en Deezer, con hasta tres intentos y espera creciente ante fallos temporales HTTP o de la API. Una ausencia válida se conserva como nulos o lista vacía; un fallo persistente detiene la ejecución con un mensaje sin credenciales y no se registra como ausencia definitiva.

En Deezer solo se aceptan coincidencias de nombre ignorando mayúsculas y espacios exteriores; no se atribuyen los fans del primer resultado aproximado a un artista distinto. Esta regla conservadora puede reducir la cobertura por diferencias de alias. Tras seleccionar candidatos nuevos, se consulta además `artist.getSimilar` para esos candidatos, sin volver a expandir su vecindad ni solicitarles otros metadatos.

Privacidad y reproducibilidad

Los datos de partida son personales: identifican los gustos musicales de los dos autores. Por ello:

- Los CSV crudos (`top_artistas*.csv`), el fichero `.env`, la caché de tokens (`.cache`) y la caché de enriquecimiento no se versionan; están excluidos en `.gitignore`.
- Solo se versionan tablas agregadas y las métricas (`resultados/metricas.json`), junto con las figuras del informe, sin nombres de artistas individuales. Las tablas identificativas se mantienen fuera del repositorio.
- Cada autor ejecuta la extracción con su propia cuenta; el token de acceso es intransferible aunque las credenciales de la aplicación se compartan.
- Los metadatos diferencian la fecha de extracción acreditada de la de análisis. La fecha original de Jorge permanece desconocida; no se sustituye por la fecha de modificación del archivo.
- La semilla de los procesos aleatorios es fija (42) y los parámetros relevantes (número de similares, soporte mínimo de género, mínimo de artistas por grupo para imputar y rango de k) están explícitos como constantes o valores predeterminados del módulo.

Decisiones de diseño

- Se ha mantenido una primera versión simplificada del script (sin consulta a Last.fm) junto a la versión final, documentando así la evolución del proceso: primero se validó el acceso a la API de Spotify y, una vez funcionando, se añadió el enriquecimiento con géneros.
- El límite de **4 géneros por artista** y el **umbral mínimo de peso 20** se fijaron para equilibrar riqueza informativa y precisión, evitando etiquetas minoritarias o poco representativas.
- La lógica de análisis se extrajo a un módulo independiente para que el cuaderno sea legible y para poder reutilizar las mismas funciones con otros usuarios o con una nueva extracción.
- Cada autor ejecuta el proceso sobre su propia cuenta, generando un CSV por persona, lo que permite comparar los perfiles musicales sin mezclar datos personales en el repositorio.

Capítulo 4: Diseño del modelo de datos

Este capítulo describe el modelo de datos construido para el análisis y las decisiones de tratamiento que lo acompañan. Los cálculos y las consultas externas están implementados como funciones en el módulo `spotify_analisis.py`, de modo que el cuaderno `AnalisisTecnicasDeCienciaDeDatos.ipynb` se limita a orquestarlas y a presentar los resultados. La separación entre lógica y presentación permite reproducir el análisis completo con un único *Restart & Run All* y reutilizar las mismas funciones con los datos de cualquier otro usuario.

Estructura de partida y consolidación

El conjunto de datos de partida (Capítulo 2) está en **formato largo**: una fila por combinación (usuario, rango, posición). Sobre él se construyen las siguientes vistas:

- **Tabla larga consolidada**: unión de los CSV de ambos autores con las columnas originales más `usuario` y `rango_orden` (1 = últimas 4 semanas, 2 = últimos 6 meses, 3 = varios años). La posición se convierte a entero y la columna `generos` se normaliza a cadena vacía cuando falta.
- **Tabla larga de etiquetas**: una fila por usuario, rango, artista y etiqueta, separando `generos` por `;`. Se normalizan las etiquetas a minúsculas. Para construir un perfil global se deduplica artista–etiqueta; para comparar rangos se conserva la pertenencia al rango. La matriz binaria de agrupamiento usa una única fila por artista.
- **Resumen por usuario y rango**: número de artistas distintos, artistas con al menos un género, porcentaje de cobertura y número de géneros distintos.
- **Tabla combinada**: permite comparar directamente los perfiles de ambos autores, que es la base de la compatibilidad del §4.5.1.

La Tabla 4.1 resume el grano y el uso de cada tabla derivada.

Cuadro 4.1: Tablas derivadas del modelo de datos.

Tabla	Grano	Uso principal
`datos_largo`	usuario × rango × posición	Base del análisis descriptivo y de la estabilidad
`artista_genero`	artista × género	Frecuencias de género y matriz binaria para el agrupamiento
`perfil_usuario_rango`	usuario × rango	Cobertura y diversidad por rango
`artistas`	artista único	Atributos enriquecidos y banderas de imputación
`similitudes`	artista × similar	Candidatos y puntuación de afinidad
`compatibilidad`	rango (incluido global)	Comparación entre autores
`afinidad`	candidato × usuario	Ranking de artistas nuevos por usuario
`clusters`	artista	Asignación de cada artista a un grupo

Enriquecimiento con fuentes adicionales

El modelo no se limita a los géneros: cada artista único se enriquece con atributos de popularidad y de similitud procedentes de Last.fm y Deezer. La Tabla 4.2 recoge los campos incorporados y su finalidad.

Cuadro 4.2: Campos incorporados en la tabla de artistas.

Campo	Fuente	Uso
`listeners`, `playcount`, `mbid`	Last.fm (`artist.getInfo`)	Popularidad general del artista
`similar_top`, `match_top`, `n_similares`	Last.fm (`artist.getSimilar`)	Vecindad de similitud para la afinidad
`deezer_fans`, `deezer_nb_album`	Deezer (búsqueda pública)	Contraste de popularidad y generación de nulos reales

Las consultas se realizan una sola vez por artista y se guardan en una caché JSON local (`cache/enriquecimiento.json`), de modo que una segunda ejecución no repite llamadas. Se aplica una pausa entre peticiones y reintentos con espera creciente ante errores temporales o límites de frecuencia. Las respuestas válidas sin información se registran con valores nulos o listas vacías; los fallos persistentes de la fuente se distinguen de esas ausencias y no se cachean como resultados válidos.

Se evaluó también **MusicBrainz** como fuente de metadatos canónicos (país, año de actividad, identificadores). Se descartó porque, sin un mapa geográfico en el alcance del proyecto, no aportaba variables que mejorasen las preguntas planteadas y añadía una consulta adicional por artista.

Cabe recordar que la *Spotify Web API* dejó de ofrecer los *endpoints* de `audio-features` y `related-artists` para aplicaciones de desarrollador nuevas, por lo que las características de audio y los artistas relacionados de Spotify no están disponibles como fuente; de ahí que Last.fm cubra la señal de similitud entre artistas.

Tratamiento de valores nulos

Los nulos aparecen en dos niveles: géneros vacíos en el CSV de extracción y atributos ausentes en las fuentes externas (artistas de nicho, bandas sonoras o proyectos minoritarios que no están dados de alta en todas las plataformas). El tratamiento es deliberadamente distinto según el tipo de variable:

- **Popularidad** (`listeners`, `playcount`, `deezer_fans`): se cuantifica el porcentaje de nulos por columna y por fuente y se imputa la mediana del género principal cuando ese grupo tiene al menos cinco artistas con dato; en caso contrario se usa la mediana global. Cada imputación queda marcada con una bandera `imputado_*`.
- **Similitud y género**: no se imputan. Un artista sin vecinos similares o sin etiquetas no tiene un sustituto razonable y tratarlo como si lo tuviera introduciría una señal artificial. Se documenta qué artistas quedan fuera de cada análisis.
- **Correlaciones de popularidad**: se calculan sobre casos completos, nunca sobre valores imputados, para no inflar artificialmente la correlación.

La Figura 5.5 muestra las ausencias sobre los 140 artistas únicos y la Tabla 4.3 resume las reglas aplicadas. En `n_similares` se cuenta expresamente el valor cero como ausencia de vecinos, aunque cero sea un recuento válido y no un nulo de almacenamiento. La imputación es una demostración de tratamiento, acorde con la limpieza descrita en la Sesión 1 [2]; no se utiliza para fabricar señal en los contrastes. El género principal se elige por frecuencia, con desempate alfabético, por lo que no equivale necesariamente a la etiqueta más representativa según Last.fm.

Cuadro 4.3: Reglas de tratamiento de valores nulos.

Variable	**¿Se imputa?**	**Criterio**
`listeners`	Sí	Mediana por género principal (grupo ≥ 5); si no, mediana global
`playcount`	Sí	Mismo criterio que `listeners`
`deezer_fans`	Sí	Mismo criterio que `listeners`
Similitud	No	Información ausente real
Género	No	Información ausente real

Características y variables del modelo

A partir de las tablas anteriores se derivan las variables que alimentan el análisis:

- **Frecuencia de género**: número de artistas distintos asociados a cada género, global y por usuario, para evitar que un artista repetido en tres rangos cuente tres veces.
- **Diversidad**: número de artistas, número de géneros, entropía de Shannon (base 2) de la distribución de géneros y cuota del género principal.
- **Estabilidad temporal**: similitud entre los conjuntos de artistas de cada par de rangos (Jaccard) y entre los vectores de frecuencia de género (coseno).

- **Compatibilidad entre usuarios**: las mismas dos métricas aplicadas a los perfiles de ambos autores, por rango y en el conjunto de los tres rangos.
- **Popularidad frente a ranking**: correlación de Spearman entre la posición en el ranking y el logaritmo de los oyentes de Last.fm, por usuario y rango.
- **Afinidad usuario–artista**: puntuación continua en $[0, 1]$ para artistas ajenos al historial, descrita en el §4.5.2.
- **Grupo de artista**: asignación de cada artista a un clúster por su vector binario de géneros, descrita en el §4.5.3.

Métodos de análisis

Compatibilidad y estabilidad

Para dos conjuntos de artistas A y B se usa el coeficiente de Jaccard:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|},$$

que vale 1 cuando los conjuntos coinciden y 0 cuando son disjuntos. Para los géneros se construye un vector de frecuencias por usuario y rango, alineado sobre la unión de géneros, y se calcula la similitud del coseno:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|}.$$

Ambas métricas se calculan para cada par de rangos (estabilidad) y entre usuarios (compatibilidad), incluyendo una fila global con artistas únicos de los tres rangos. Para Jaccard se usa la tabla original completa, incluidos los artistas sin etiquetas; para el coseno se usa la tabla de géneros. Así, la falta de etiquetas no altera los conjuntos de artistas. El resultado es descriptivo y no se generaliza a una población.

Afinidad usuario–artista

No existe una fuente fiable de ejemplos negativos (Spotify no expone artistas bloqueados u ocultados), por lo que se descarta un clasificador supervisado y se opta por una **heurística de vecindad entre artistas** basada en la similitud publicada por Last.fm. No se entrena un modelo propio de contenido acústico ni se considera que esa similitud externa sea una preferencia observada del usuario. Para cada usuario u se define el peso de un artista a de su historial como

$$w_u(a) = \frac{51 - \min_r \text{posición}_r(a)}{50},$$

de modo que el primer puesto de cualquier rango pesa aproximadamente 1 y el puesto 50 pesa 0,02. Para un artista candidato c con vecinos similares $s \in \text{Sim}(c)$ y puntuaciones de similitud $\text{match}(c, s)$, la afinidad estimada es

$$S(c, u) = \frac{\sum_{s \in \text{Sim}(c)} \text{match}(c, s) \, w_u(s)}{\sum_{s \in \text{Sim}(c)} \text{match}(c, s)}.$$

Si el artista no tiene vecinos o la suma de sus pesos es cero, la puntuación se considera **no calculable**, no igual a cero. En cambio, si hay vecinos pero ninguno aparece en el ranking del usuario, el resultado sí es cero. Los candidatos se generan a partir de los diez artistas mejor situados de cada usuario, excluyendo los presentes en cualquiera de los rankings y conservando hasta veinte con mayor similitud media. A continuación se consultan los vecinos propios de cada candidato, necesarios para evaluar la fórmula. La media entre usuarios se calcula solo si ambas puntuaciones están disponibles; los no calculables no entran en el top mostrado.

La puntuación no es una probabilidad de que guste un artista ni el porcentaje de escucha esperado. La selección favorece candidatos relacionados con los artistas de partida, por lo que su distribución no representa un conjunto aleatorio de artistas desconocidos.

Como comprobación descriptiva se aplica un esquema *leave-one-out*: se oculta cada artista del top-10, se recalcula su puntuación sin él y se compara con la de los candidatos-control mediante medianas y la prueba U de Mann-Whitney. No es una evaluación supervisada ni una medida de acierto predictivo. Los candidatos no son ejemplos negativos y su selección no es independiente de los favoritos; por ello el estadístico y su valor p se conservan como comprobación exploratoria, sin convertirlos en una garantía de recomendación o en evidencia confirmatoria.

Agrupamiento de artistas

Cada artista se representa por un vector binario de géneros (1 si el artista tiene ese género). Se conservan los géneros presentes en al menos dos artistas y los artistas con al menos un género; las exclusiones se documentan. Sobre esa matriz se aplica K-Means con semilla fija (42) y diez inicializaciones. Se examinan la inercia y el coeficiente de silueta para $k \in [2, 8]$. La regla automática elige el menor k cuya silueta está a una distancia máxima de 0,02 del mejor valor observado; la inercia se presenta como diagnóstico complementario, no interviene en esa regla. Los grupos se etiquetan por las tres etiquetas con mayor cociente entre prevalencia interna y global (*lift*) y se proyectan en dos dimensiones mediante PCA, que es solo una ayuda visual: el agrupamiento se realiza en el espacio completo de géneros.

Decisiones de implementación y reproducibilidad

- **Semilla fija** (42) en K-Means y en cualquier proceso aleatorio.
- **Caché persistente** de respuestas válidas para repetir el análisis sobre la misma instantánea de metadatos, sin garantizar que una extracción nueva de las APIs produzca los mismos valores.
- **Credenciales fuera del repositorio**: el fichero `.env` y la caché de tokens no se versionan; los CSV con nombres de artistas tampoco.
- **Salidas separadas**: las tablas con nombres de artistas quedan en local y solo se publican agregados y figuras sin etiquetas identificativas.
- **Parámetros explícitos**: número de similares (20), mínimo de soporte de género (2), mínimo de artistas por grupo para imputar (5) y rango de k (2–8) están explícitos como constantes o valores predeterminados del módulo.

Limitaciones del modelo

- **Dos usuarios**: los índices de compatibilidad describen a estos dos autores, no a una población.
- **Etiquetas de género colaborativas**: Last.fm es una folksonomía; las etiquetas pueden ser ruidosas, redundantes o mezclar género con país o época.
- **Datos dinámicos**: el top de Spotify cambia con el tiempo. Sería preferible acreditar extracciones simultáneas, pero solo se dispone de la fecha original de Pablo; la de Jorge se mantiene desconocida.
- **Cobertura desigual**: los artistas de nicho tienen menos probabilidades de estar en Last.fm o Deezer, lo que puede sesgar las comparaciones de popularidad.
- **Sin características de audio**: la retirada de `audio-features` impide usar *danceability*, *energy* u otras variables acústicas.

Capítulo 5: Resultados y visualización

Este capítulo presenta resultados del análisis de los dos CSV recibidos. Las cifras se exportan en `resultados/metricas.json` y en tablas CSV; las figuras se generan desde el mismo cuaderno. La audiencia es el profesorado de la asignatura y el objetivo es explicar diferencias y coincidencias, no elaborar un catálogo de artistas. Siguiendo la Sesión 6 [6], se emplean barras para comparar magnitudes, mapas de calor para matrices y dispersión para relaciones entre variables; se evita el doble eje vertical.

Composición y diversidad de etiquetas

La cobertura de etiquetas por rango está entre el 94 % y el 100 %. La Tabla 5.1 separa el tamaño del ranking del número de etiquetas diferentes y de su entropía. Se cuentan asociaciones artista–etiqueta deduplicadas: un artista puede aportar varias, por lo que estas cifras no miden minutos ni reproducciones.

Usuario	Rango	Artistas	Con etiqueta	Etiquetas	Entropía (bits)
Jorge	4 semanas	48	48	64	5,4033
Jorge	6 meses	50	49	64	5,3244
Jorge	Varios años	50	49	66	5,3752
Pablo	4 semanas	50	47	57	5,1208
Pablo	6 meses	50	49	60	5,1231
Pablo	Varios años	50	50	56	5,0982

Cuadro 5.1: Diversidad de etiquetas por usuario y rango, calculada sobre artistas con etiquetas.

En el perfil global de Jorge, `rock` aparece en 23 artistas distintos, `alternative` en 16 y `soundtrack` en 14. En Pablo predominan `rap` (23), `rock` (16), `hip-hop` (15) y `hip hop` (14). Estas dos últimas grafías se mantienen como etiquetas distintas: no deben sumarse directamente, ya que pueden coexistir en un mismo artista. También sobreviven etiquetas de procedencia como `spain` o `japanese`. Por tanto, se analiza una folksonomía musical parcialmente filtrada, no una taxonomía canónica de géneros.

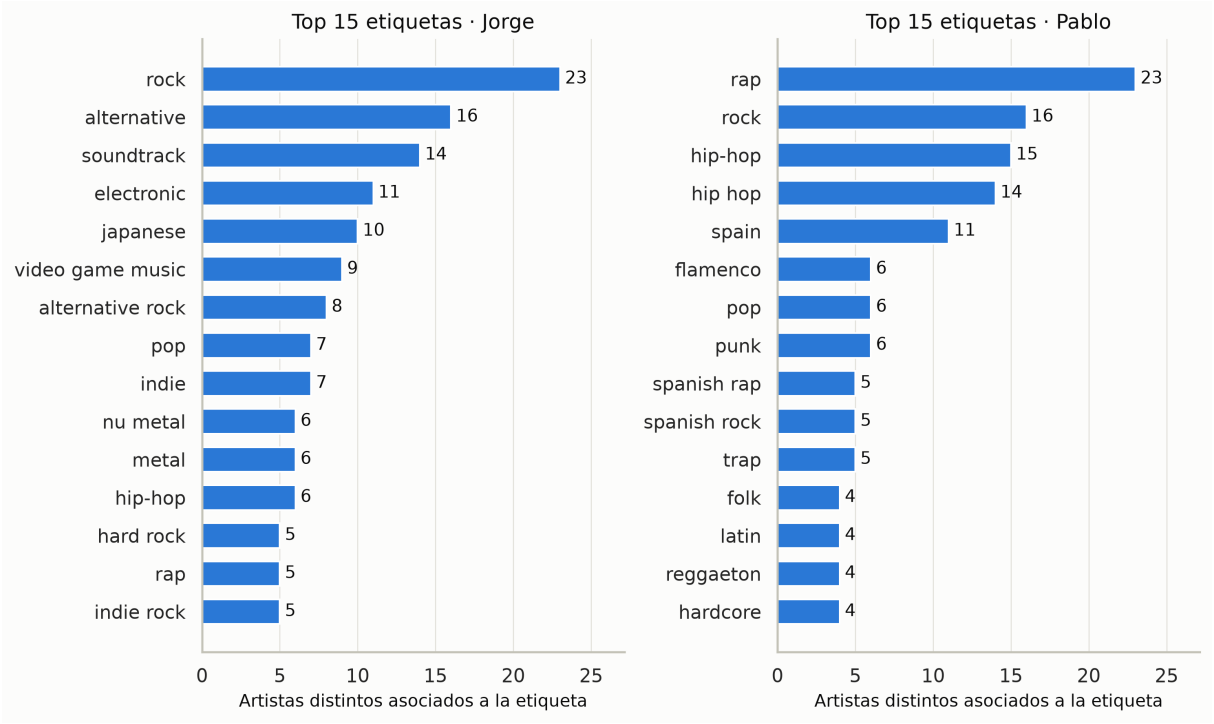


Figura 5.1: Quince etiquetas más frecuentes por usuario. Las barras horizontales facilitan leer nombres largos; ambos paneles comparten escala y muestran el número de artistas distintos.

Jorge presenta más etiquetas distintas y mayor entropía en los tres rangos: 5,3244–5,4033 bits frente a 5,0982–5,1231 en Pablo. Esto describe una distribución de etiquetas más dispersa en esta muestra, no demuestra una mayor diversidad musical objetiva: influyen el número de etiquetas por artista, sus sinónimos y la cobertura de Last.fm. La etiqueta más frecuente representa aproximadamente el 9,4–10,2 % de las asociaciones de Jorge y el 12,1–13,5 % de las de Pablo.

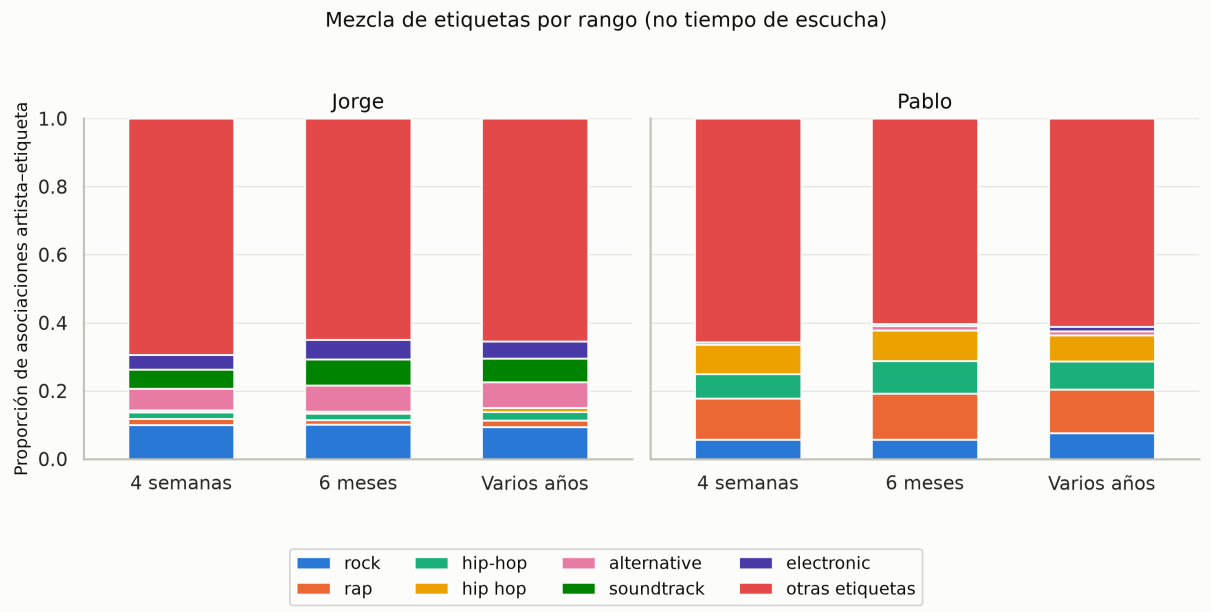


Figura 5.2: Proporciones de asociaciones artista–etiqueta por rango. Las siete etiquetas destacadas y sus colores se mantienen entre paneles; el resto se agrupa. El denominador no es el tiempo de escucha.

Coincidencia entre ventanas temporales

Los conjuntos de artistas de cada usuario muestran coincidencias apreciables entre ventanas. Jorge tiene Jaccard de 0,5806 entre cuatro semanas y seis meses, 0,5312 entre cuatro semanas y varios años, y 0,6129 entre seis meses y varios años. Para Pablo son 0,5625, 0,5152 y 0,6667, respectivamente. En ambos casos la mayor coincidencia corresponde a medio y largo plazo.

Los cosenos de etiquetas son aún más elevados: 0,9566–0,9777 en Jorge y 0,9471–0,9717 en Pablo. La composición etiquetada es, por tanto, más parecida que la identidad exacta de los artistas. Hay 31 artistas de Jorge y 34 de Pablo presentes en los tres rangos; 25 y 32, respectivamente, aparecen en uno solo. No se interpreta esta coincidencia como una serie temporal independiente, porque las ventanas se solapan.

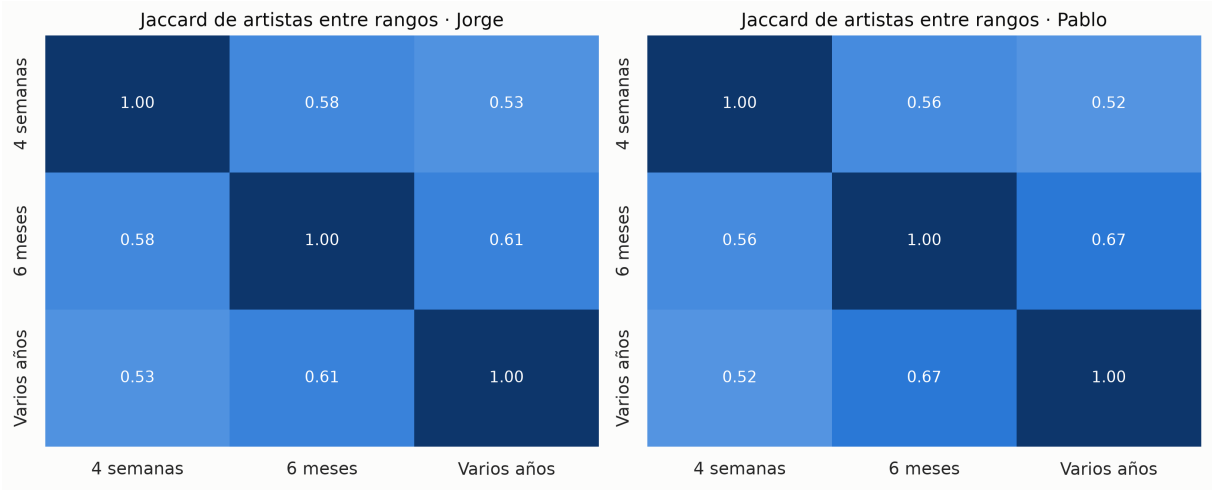


Figura 5.3: Jaccard de artistas entre rangos, incluidos los artistas sin etiquetas. La escala común de 0 a 1 y las anotaciones permiten comparar ambas matrices; la diagonal vale 1 por construcción.

Compatibilidad entre usuarios

La coincidencia global es de **5 artistas sobre una unión de 140**, de modo que $J = 5/140 = 0{,}0357$. El Jaccard por ventana permanece entre 0,0309 y 0,0417. La similitud del coseno de etiquetas es mayor: 0,3247 en cuatro semanas, 0,3110 en seis meses y 0,4112 en varios años; al reunir las tres ventanas alcanza 0,4686, con 27 etiquetas comunes. No son porcentajes equivalentes de compatibilidad: Jaccard compara identidades y el coseno compara composiciones etiquetadas.

Rango	Artistas comunes	Jaccard	Coseno
4 semanas	3	0,0316	0,3247
6 meses	4	0,0417	0,3110
Varios años	3	0,0309	0,4112
Global	5	0,0357	0,4686

Cuadro 5.2: Dos medidas complementarias de coincidencia entre usuarios. Los artistas sin etiquetas se mantienen en el cálculo de Jaccard.

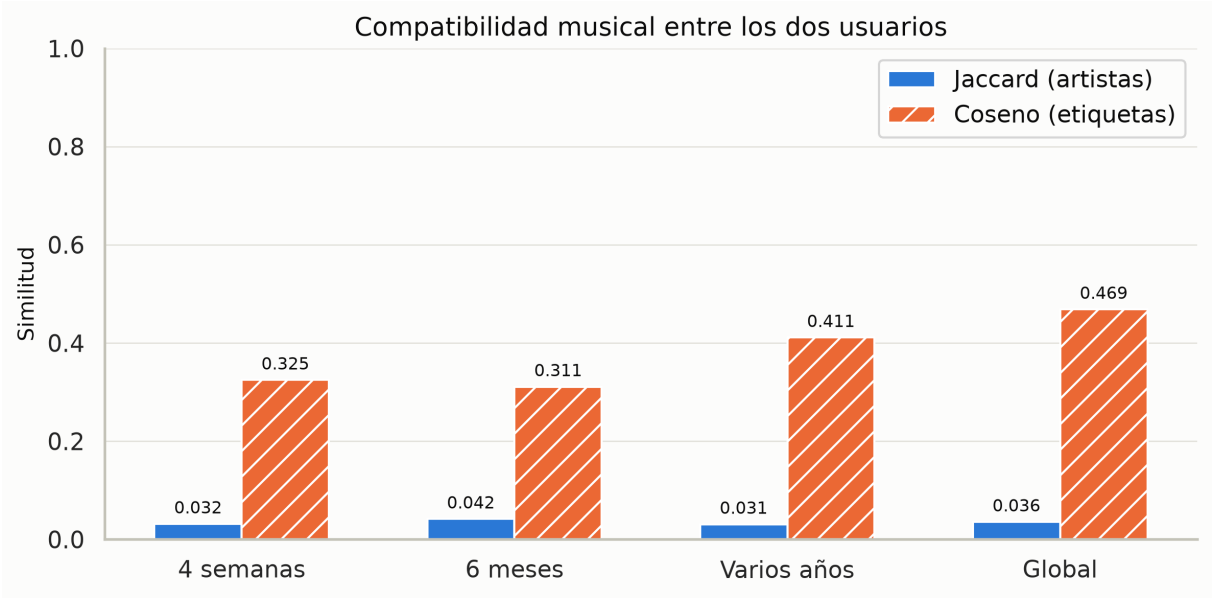


Figura 5.4: Jaccard de artistas y coseno de etiquetas por ventana y global. Se conserva una escala común 0–1 y se distinguen las métricas mediante leyenda y trama, además del color.

El resultado permite afirmar que las listas concretas son muy distintas, pero comparten parte del vocabulario musical, incluido `rock`. La diferencia entre medidas es coherente con que dos personas escuchen artistas distintos vinculados a etiquetas semejantes. No se transforma el coseno en una valoración personal ni en una probabilidad de compartir gustos.

Cobertura de las fuentes y tratamiento de ausencias

El enriquecimiento se completó el 4 de noviembre de 2026. Last.fm devuelve oyentes, reproducciones y al menos un vecino para los 140 artistas del historial. Esto no implica cobertura perfecta de todos sus atributos: faltan 20 identificadores MusicBrainz. Deezer aporta fans y número de álbumes para 136 artistas con coincidencia exacta de nombre; los cuatro restantes se mantienen ausentes, sin atribuirles resultados aproximados.

Información ausente	Artistas	Porcentaje
Etiquetas del CSV	5	3,57 %
Oyentes Last.fm	0	0,00 %
Reproducciones Last.fm	0	0,00 %
Identificador MusicBrainz	20	14,29 %
Sin vecinos similares	0	0,00 %
Fans Deezer	4	2,86 %
Álbumes Deezer	4	2,86 %

Cuadro 5.3: Ausencias sobre los 140 artistas únicos. Los campos no son excluyentes: un artista puede carecer de varios atributos.

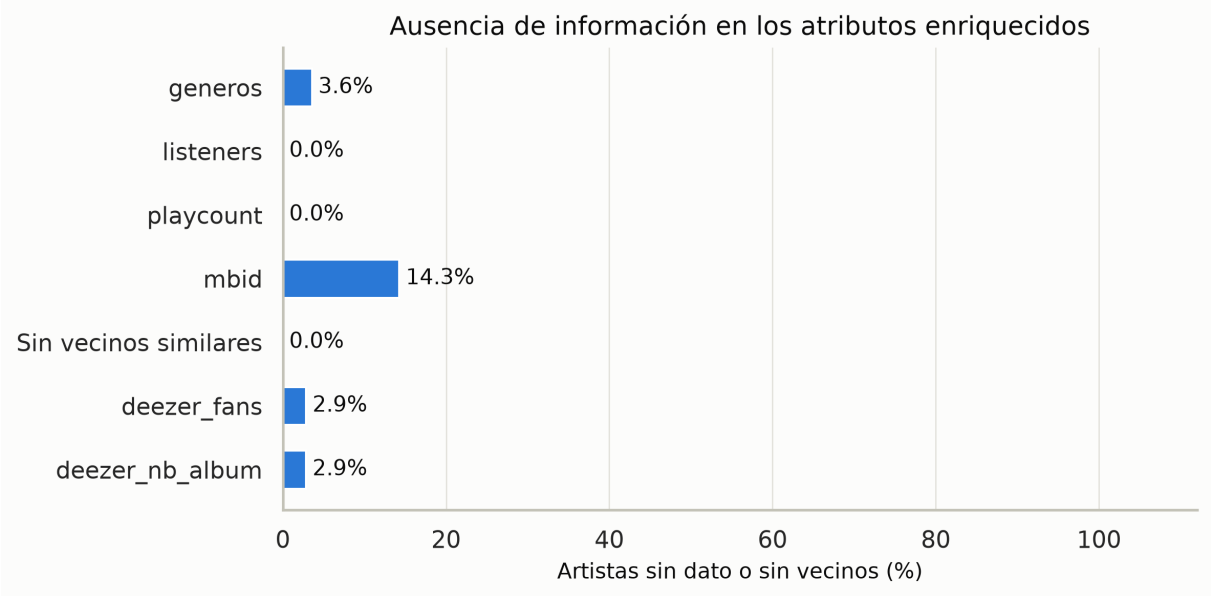


Figura 5.5: Porcentaje sin información por atributo. Las barras parten de cero y tienen una escala porcentual común; "sin vecinos" cuenta listas vacías, no solo nulos de almacenamiento.

El procedimiento de imputación no modifica ningún valor de oyentes o reproducciones, porque están completos. Genera cuatro valores de fans en una columna separada, según las reglas de mediana descritas en el Capítulo 4; la mediana global observada de fans es 16 042,5. Las columnas originales y las banderas de imputación se conservan. Los análisis siguientes usan observaciones reales: la correlación entre fuentes tiene 136 casos, no 140.

Popularidad externa y posición personal

Usuario	Rango	n	Spearman ρ	Valor p
Jorge	4 semanas	48	0,1845	0,2092
Jorge	6 meses	50	−0,0033	0,9818
Jorge	Varios años	50	−0,0337	0,8165
Pablo	4 semanas	50	−0,1055	0,4659
Pablo	6 meses	50	0,2548	0,0741
Pablo	Varios años	50	0,3275	0,0202

Cuadro 5.4: Correlación entre posición numérica y logaritmo de oyentes de Last.fm, solo con casos observados. Los valores p son exploratorios y no están corregidos por las seis comparaciones.

No aparece una asociación de igual signo y magnitud en los seis perfiles. La mayor correlación es la de Pablo en varios años ($\rho = 0{,}3275$): al aumentar la posición numérica, es decir, al bajar en el ranking, tiende a aumentar la popularidad externa. No significa que los artistas más populares estén mejor situados, sino lo contrario. Su valor p sin ajustar es 0,0202, pero se han examinado seis combinaciones y no existe un diseño confirmatorio; tampoco las ventanas son independientes. El resultado se describe como una asociación moderada y localizada, sin generalizar una preferencia estable o causal.

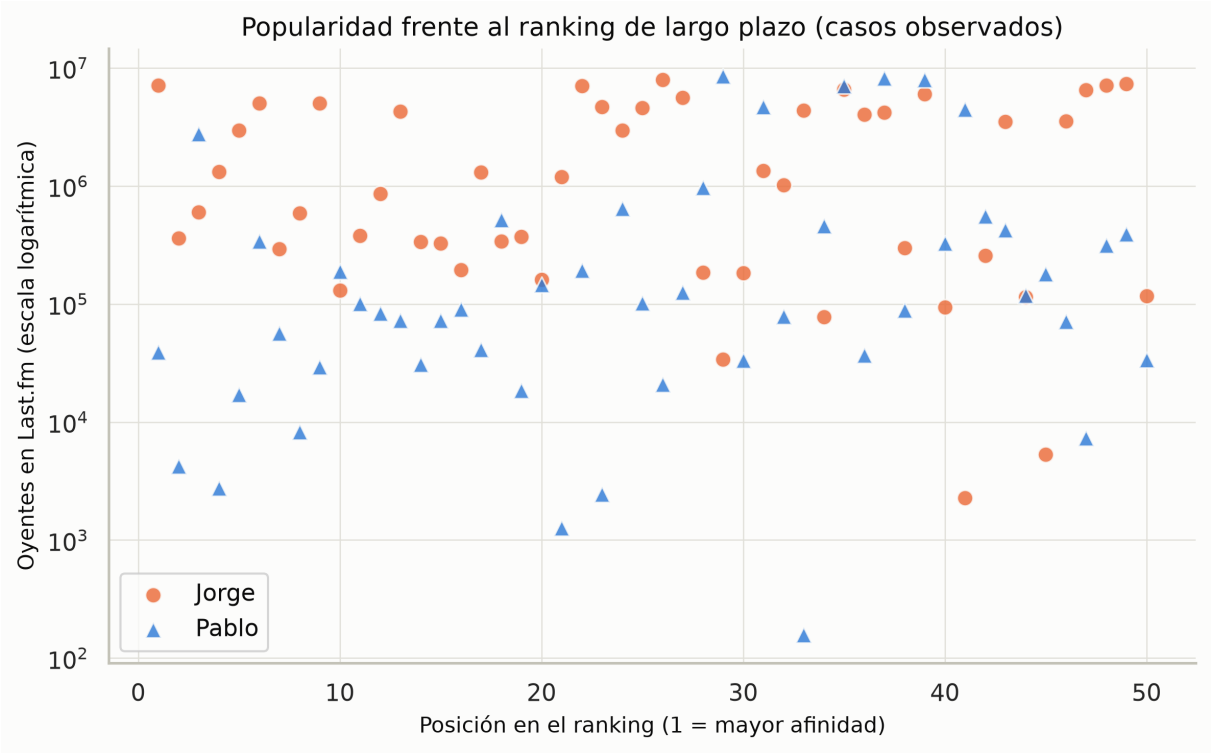


Figura 5.6: Oyentes externos frente a posición personal en la ventana larga. La escala logarítmica permite representar varios órdenes de magnitud; usuario y forma de los puntos se mantienen identificados en la leyenda. Cada punto es una entrada del ranking, no una reproducción.

Entre las dos medidas externas de popularidad, oyentes de Last.fm y fans de Deezer, se obtiene $\rho = 0{,}6830$ con 136 pares observados ($p \simeq 5{,}19 \times 10^{-20}$). La relación positiva indica ordenaciones parcialmente concordantes dentro del conjunto seleccionado, pero no intercambiabilidad: son plataformas y acciones de usuario distintas. No se utiliza esta asociación para rellenar los cuatro fans ausentes ni se presenta como representativa de todos los artistas de ambas plataformas.

Afinidad de candidatos nuevos

Se generan 20 candidatos fuera de los dos historiales y se consultan sus propios vecinos. Los **20 son puntuables para ambos usuarios**; esta cobertura se refiere a la disponibilidad del cálculo, no a que encajen con ambos perfiles. De hecho, **ninguno de los veinte obtiene puntuación positiva para los dos usuarios a la vez**. Cada uno presenta solapamiento ponderado con un perfil y cero con el otro.

La Figura 5.7 muestra diez candidatos ordenados por la media de sus dos puntuaciones, con identificadores anónimos. El candidato C01 obtiene 0,2175 en Jorge y 0 en Pablo; C02 obtiene 0 y 0,2156, respectivamente. Sus medias, 0,1087 y 0,1078, no representan una afinidad compartida. La media prioriza una puntuación unilateral relativamente alta, de modo que no debe interpretarse este top como una selección de consenso. Un cero significa ausencia de vecinos coincidentes en el historial truncado, no rechazo declarado del artista.

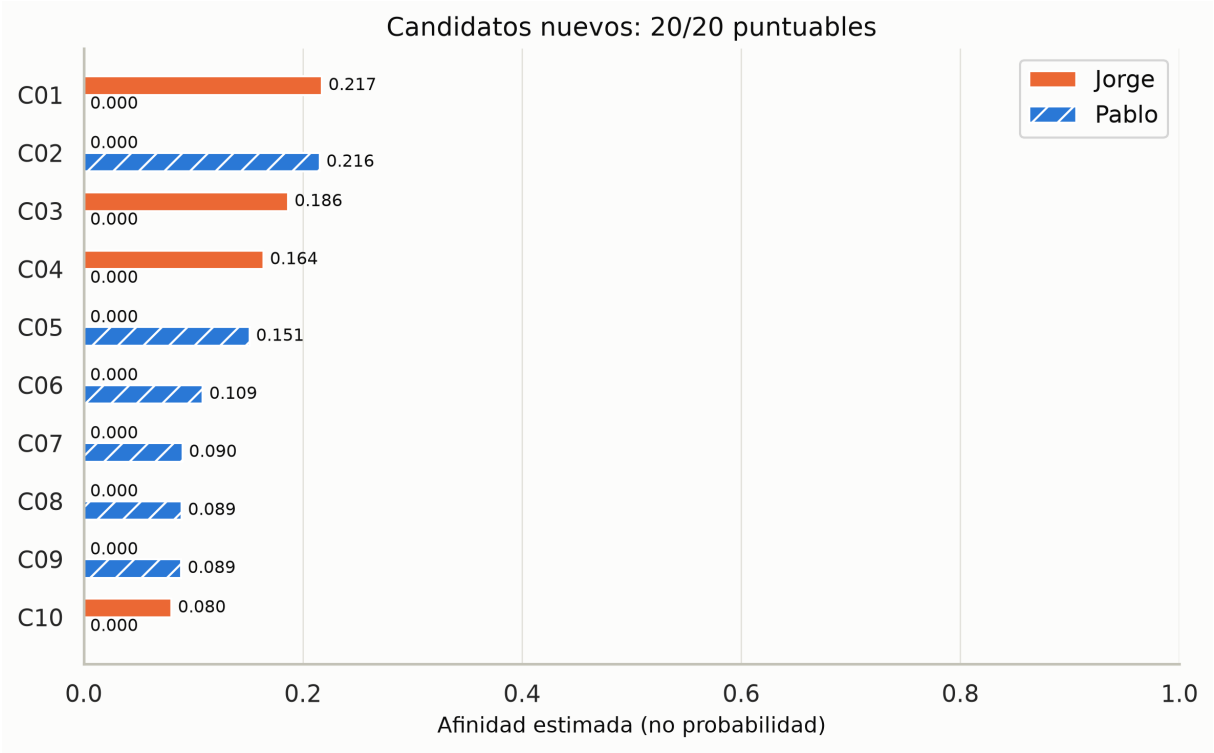


Figura 5.7: Diez candidatos anónimos con mayor afinidad media. El eje común 0–1, las etiquetas numéricas y la trama permiten ver tanto las diferencias como los ceros. La cobertura 20/20 indica que el cálculo está disponible, no una tasa de acierto.

Usuario	Ocultos	Controles	Mediana ocultos	Mediana controles	Valor p
Jorge	10	20	0,1069	0,0435	0,0801
Pablo	10	20	0,1647	0,0000	0,000205

Cuadro 5.5: Comprobación exploratoria *leave-one-out*. El valor p corresponde a la prueba U unilateral (ocultos mayores que controles); los controles no son ejemplos negativos ni una muestra independiente.

Las medianas de los favoritos ocultos son mayores que las de los candidatos-control en ambos usuarios. Los estadísticos U son 132,0 en Jorge y 177,5 en Pablo. Esta comparación muestra el comportamiento interno de la heurística, pero no proporciona precisión, tasa de acierto ni garantía de que gusten las recomendaciones: candidatos y favoritos comparten el mecanismo de selección y no se dispone de valoraciones independientes.

Agrupamiento exploratorio

De los 140 artistas, cinco carecen de etiquetas y otros dos quedan sin ninguna tras exigir soporte mínimo de dos artistas por etiqueta. La matriz final tiene **133 artistas y 52 etiquetas**; se descartan 78 etiquetas de soporte uno. Esta selección limita la representación de estilos raros y debe tenerse en cuenta al interpretar los grupos.

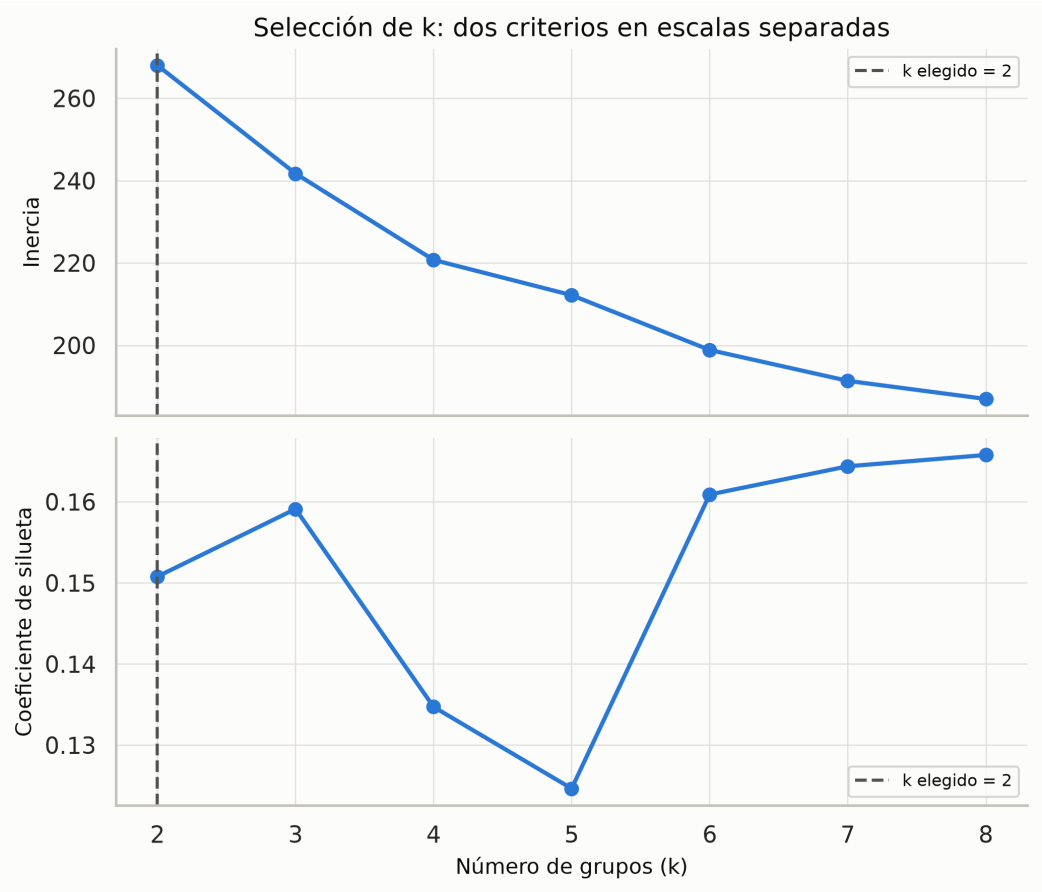


Figura 5.8: Inercia y silueta para $k = 2, \ldots, 8$, en paneles con escalas independientes. La inercia disminuye al aumentar el número de grupos, pero no constituye por sí sola una mejora de interpretación.

La mejor silueta observada es 0,1658 con $k = 8$. La regla predefinida elige el menor k cuya silueta queda a menos de 0,02 del máximo: resulta $k = 2$, con silueta 0,1508 e inercia 267,9952. La silueta es baja en todos los casos, por lo que la separación no es fuerte. La elección prioriza una descripción sencilla; no demuestra que existan exactamente dos familias musicales naturales.

El grupo 0 contiene 28 artistas y se caracteriza, por sobrerrepresentación respecto al conjunto, mediante `spanish hip-hop`, `rap` y `spanish rap`. El grupo 1 contiene 105 artistas y sus etiquetas de mayor sobrerrepresentación son `80s`, `alternative` y `alternative metal`; su mayor tamaño y heterogeneidad impiden resumirlo como un único género. Las etiquetas del perfil se eligen por cociente de prevalencias (*lift*), no por frecuencia absoluta dentro del grupo.

Grupo	Artistas únicos	Presentes en Jorge	Presentes en Pablo
0	28	5	24
1	105	64	45

Cuadro 5.6: Pertenencia de los artistas agrupados a los rankings de cada usuario. Un artista compartido cuenta en ambas columnas, por lo que estas no suman el total de artistas únicos.

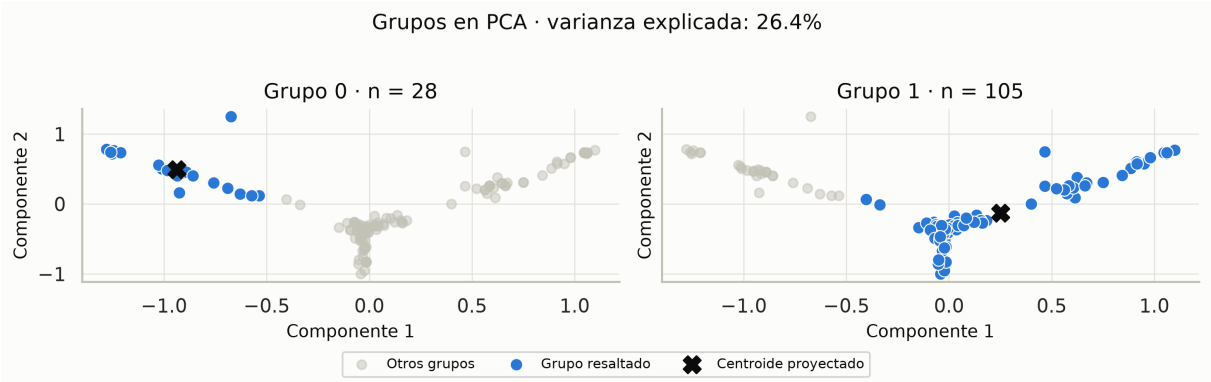


Figura 5.9: Proyección PCA con un panel por grupo. El azul destaca el grupo y el gris da contexto; la cruz representa su centroide proyectado. El ajuste de K-Means se realiza en las 52 dimensiones originales, no en este plano.

Las dos primeras componentes explican el **26,42 %** de la varianza. La proyección pierde casi tres cuartas partes de la variación: ni la proximidad ni la separación visual en dos dimensiones bastan para validar el agrupamiento. El grupo orientado al rap reúne una fracción mayor del perfil de Pablo (24 de sus 69 artistas agrupados) que del de Jorge (5 de 69), en consonancia con las frecuencias de etiquetas, sin constituir una prueba independiente de ellas.

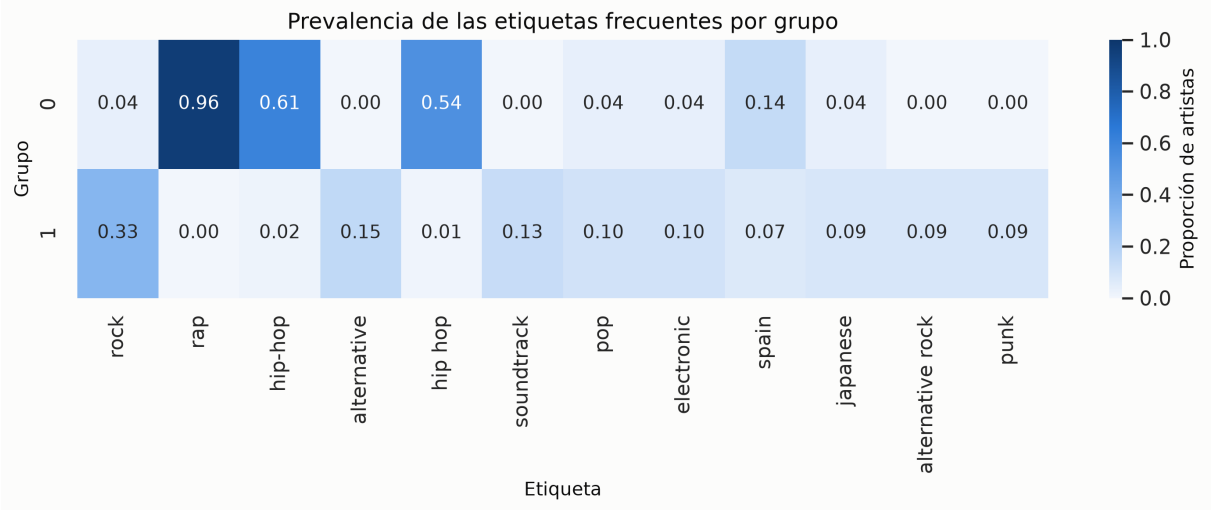


Figura 5.10: Prevalencia interna de las doce etiquetas más frecuentes de la matriz. La escala secuencial común representa proporciones entre 0 y 1; esta vista complementa las etiquetas elegidas por *lift*.

Capítulo 6: Conclusiones

Respuesta a las preguntas del proyecto

El análisis de 298 registros y 140 artistas únicos permite describir los perfiles de los dos autores, sin extrapolarlos a una población:

1. **Los artistas concretos coinciden poco, pero las etiquetas comparten más estructura.** Solo cinco artistas son comunes y el Jaccard global es 0,0357. El coseno de etiquetas alcanza 0,4686. No son resultados contradictorios: comparan identidades y composiciones diferentes. Pablo presenta mayor presencia de etiquetas relacionadas con rap e hip-hop, mientras Jorge combina rock, alternative y etiquetas de bandas sonoras.

2. **La composición etiquetada es bastante estable entre ventanas solapadas.** Los cosenos dentro de cada usuario se sitúan entre 0,9471 y 0,9777, mientras los Jaccard de artistas van de 0,5152 a 0,6667. Cambian más los nombres concretos que la distribución de etiquetas. Esta observación no demuestra estabilidad futura ni una evolución longitudinal, porque los rangos se solapan.

3. **Jorge presenta mayor dispersión de etiquetas en esta muestra.** Sus entropías son superiores a las de Pablo en los tres rangos. La conclusión se refiere al vocabulario colaborativo obtenido, no a una escala objetiva de amplitud cultural: las etiquetas son múltiples, redundantes y de cobertura desigual.

4. **La posición personal no reproduce de forma uniforme la popularidad externa.** Las correlaciones cambian de signo entre ventanas y usuarios. El mayor valor es 0,3275 en el largo plazo de Pablo, pero no se convierte en una regla general a partir de seis comparaciones exploratorias. Last.fm y Deezer sí ofrecen medidas parcialmente concordantes en los 136 artistas con ambos datos ($\rho = 0{,}6830$), sin ser medidas equivalentes.

5. **Calcular afinidad no equivale a recomendar para los dos usuarios.** Los veinte candidatos tienen datos suficientes, pero ninguno obtiene puntuación positiva en ambos perfiles. La media de puntuaciones puede destacar una coincidencia unilateral y no debe presentarse como consenso. La comprobación con favoritos ocultos describe el funcionamiento de la heurística, no su capacidad predictiva sobre valoraciones nuevas.

6. **El agrupamiento ofrece una descripción sencilla, pero débilmente separada.** La regla de silueta selecciona dos grupos sobre 133 artistas y 52 etiquetas, con silueta 0,1508. Un grupo ligado al rap está más representado en Pablo; el restante es amplio y heterogéneo. El 26,42 % de varianza explicado por la PCA bidimensional obliga a interpretar su imagen con cautela. No se han descubierto categorías musicales naturales ni validado un clasificador.

Aprendizajes del proceso de ciencia de datos

La aportación del proyecto no se limita a calcular índices. Se ha recorrido un ciclo de definición del problema, comprensión de las fuentes, preparación, modelado exploratorio y comunicación, siguiendo el marco CRISP-DM presentado en la asignatura. La elección de CSV y JSON resulta proporcional a la escala del conjunto; Unicode conserva los nombres originales y las figuras PNG evitan pérdidas de compresión. Las representaciones responden a preguntas concretas y mantienen denominadores, escalas y colores comparables.

La integración de fuentes exige distinguir dato ausente de error de servicio, coincidencia de nombre de búsqueda aproximada y observación real de valor imputado. También exige conservar a los artistas sin etiquetas cuando la métrica no necesita géneros. Excluirlos de Jaccard habría cambiado indebidamente su denominador; imputar popularidad antes de correlacionar habría añadido información artificial. La caché local y las pruebas con respuestas simuladas permiten controlar estas decisiones sin exponer credenciales ni repetir consultas válidas.

El repositorio conserva código, agregados y figuras, pero no distribuye los rankings personales ni la caché. La reproducibilidad numérica requiere los mismos CSV y la misma instantánea de metadatos externos; nuevas consultas pueden devolver valores distintos. La fecha original de Jorge permanece desconocida, en vez de sustituirse por una fecha inferida.

Limitaciones y trabajo futuro

- **Muestra y selección**: solo hay dos usuarios y listas truncadas a un máximo de 50 artistas. No se observan todas las escuchas ni los minutos dedicados a cada artista; tampoco hay observaciones independientes por cada fila.
- **Temporalidad**: las ventanas se solapan y no se acredita que las dos extracciones sean simultáneas. Para estudiar cambios reales harían falta instantáneas fechadas y repetidas con un protocolo común.
- **Etiquetas**: el filtro manual no elimina todos los países, sinónimos o metaetiquetas. Una mejora sería construir un diccionario documentado de equivalencias, conservar también las etiquetas originales y repetir las métricas para estudiar su sensibilidad a esa normalización.
- **Identificación y cobertura**: los nombres no son identificadores universales; los alias y homónimos pueden causar pérdidas o atribuciones ambiguas. La coincidencia exacta de Deezer es conservadora, pero no resuelve por sí sola la desambiguación. Los huecos de cobertura pueden estar relacionados con el tipo de artista.
- **Afinidad**: la señal procede de vecinos de Last.fm, no de características acústicas observadas. Los candidatos se seleccionan a partir de los favoritos y los no escuchados no son ejemplos de rechazo. La comprobación *leave-one-out* no constituye validación predictiva independiente. Antes de desplegar recomendaciones haría falta recoger valoraciones explícitas y evaluar candidatos nuevos con un diseño separado.
- **Agrupamiento**: K-Means sobre etiquetas binarias y un filtro de soporte produce una partición exploratoria; sería necesario estudiar estabilidad, sensibilidad a sinónimos y métricas alternativas antes de atribuirle un significado general.

Bibliografía

[1] Indicaciones sobre el trabajo de la asignatura. Técnicas de Ciencia de Datos. Documento facilitado con el proyecto, `info/trabajoFinal.pdf`.

[2] Adrián Inés Armas. *Sesión 1: Introducción*. Universidad de La Rioja. Material docente: ciclo de vida, limpieza y metodologías de proyectos.

[3] *Fuentes Públicas de Datos para Proyectos de Ciencia de Datos*. Material de la Sesión 1: clasificación de fuentes y APIs.

[4] Adrián Inés Armas. *Sesión 2: Codificación y compresión*. Universidad de La Rioja. Diapositivas 9–12: Unicode/UTF-8; compresión sin pérdida y PNG.

[5] Adrián Inés Armas. *Sesión 3: Datos, formatos y herramientas HDF5*. Universidad de La Rioja. Diapositivas 24–26: CSV y JSON; formatos para grandes volúmenes.

[6] Adrián Inés Armas. *Sesión 6: Visualización de datos*. Universidad de La Rioja. Diapositivas 4–9 y 24: audiencia, objetivo y buenas prácticas.